Flink 实战宝典

Flink 理论与实战

作者：左元
组织：尚硅谷
时间：April 12, 2020
版本：0.1

ElegantLaTeX Program

完成比完美更重要！

目录

第一部分

Flink 的使用

第 一 章 第一章，流式处理理论概述

第 二 章 第二章，Flink 框架快速上手

第 三 章 第三章，Flink DataStream API

第 四 章 第四章，基于时间和窗口的算子

第 五 章 第五章，Flink 状态编程

第六章 第六章，Flink DataSet API

第 七 章 第七章，Flink 与外部系统的交互

第八章 第八章，Flink Table API & SQL

第 九 章　第九章，Flink CEP 库的使用

第二部分

Flink 的部署与运维

第 十 章 第十章，Flink 应用的监控

第 十一 章 第十一章，如何部署 Flink 集群

第 十二 章　第十二章，Flink 集群的高可用

第三部分

Flink 内核与优化

第 十三 章 第十三章，Flink 运行时架构

第 十四 章　第十四章，Flink 状态的原理

第 十五 章　第十五章，Flink 的容错机制

第 十六 章 第十六章，Flink 作业的调度

第 十七 章 第十七章，Flink 内存管理的特点

第 十八 章　第十八章，Flink 的网络 IO 机制

第 十九 章 第十九章，Flink 常见优化措施

过早优化是万恶之源。

高德纳

任何程序的编写其实遵循三个阶段。第一，编写出一个可以运行的程序。第二，确保这个程序是正确的。第三，优化这个程序。所以高德纳才说：“过早优化是万恶之源”。而 Flink 程序与其他的程序的优化策略的基本道理是一样的，也就是尽量减少计算密集型和 IO 密集型这两种运算。

我们先来看一下在开发 Flink 程序时常犯的一些错误：

首先 Flink 的程序开发流程如下图所示：

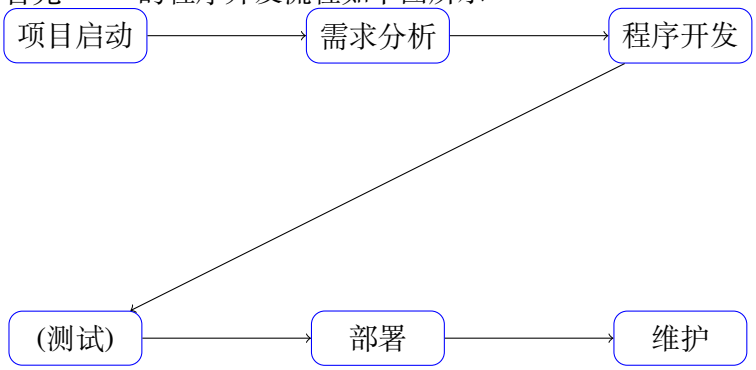

19.1 在项目启动的时候

- 不使用一种迭代式的开发，而是想要毕其功于一役。
- 刚学了一些 Flink 基础知识，就想用 Flink 来解决公司最难的需求。
- 事先没有流处理的知识，直接开始使用 Flink 进行编程。
- 事先没有经过 Flink 编程方面的训练，例如：基本 API 的熟悉，基本的调优训练等等。
- 不和社区进行交流，不在社区中搜索可能已经存在的答案。例如不使用 StackOverflow、Flink Documentation、Flink Jira 等常见工具。

19.2 在分析需求的时候

- 不考虑程序的一致性，例如是否允许丢失数据，是否允许数据重复计算。
- 不考虑程序后续的迭代和程序
- 不考虑需要解决的问题的规模，例如数据量的大小，数据流高峰期的数据量等等。
- 没有细致的分析真实的业务需求

19.3 在开发的时候

- 没有细致思考到底使应该使用 DataStream API 还是 Table API & SQL?
- 对 Flink 的类型系统理解不深，盲目使用了嵌套过深或者非常复杂的数据结构（例如深度嵌套的 POJO CLASS 或者 case class）
- 胡乱使用 keyBy() 函数
- 在不同的任务之间共享静态变量，从而造成了死锁、竞争等同步问题。
- 在 UDF 函数中随意开启新的线程，会造成非常难以调试的 bug，例如检查点相关的问题。
- 随便自定义窗口函数，而没有使用 Flink 默认的函数。
- 没有将初始化的代码放在富函数的 open 方法中，而是放在了例如 flatMap、map、filter 函数中。

19.4 维护

由于 Flink 更新非常频繁，所以不要随便对程序进行升级。

第 二十 章　第二十章，流的去重及其优化

第 二十一 章 第二十一章，如何解决数据倾斜

第四部分

Flink 实时数仓项目